Neuronale Operatoren zur Strömungssimulation um Kristalle

U-Net vs. Fourier Neural Operator – Aktueller Stand

Paul Baselt

Betreuer-Meeting – Masterarbeit

4. März 2026

Agenda

1. Grundlagen & Problemstellung
2. Modellarchitekturen
3. Experiment 1: Einzelkristall ($n = 1$)
4. Experimente 2 & 3: Multi-Kristall
5. Analyse & Diskussion
6. Fazit & Ausblick

Physikalische Situation & Lernziel

Setup:

- Kristalle eingebettet in viskose Matrix
- Gebiet: 256×256-Gitter, $[-1, 1]^2$ km
- Stokes-Gleichungen (niedrige Reynolds-Zahl):

$$-\nabla p + \eta \, \Delta \mathbf{v} = 0, \qquad \nabla \cdot \mathbf{v} = 0$$

- Numerische Referenz: **LaMEM** (FEM-Solver) – korrekt, aber rechenintensiv

Ziel: Neuronales Netz sagt Strömungsfeld vorher – *ohne* FEM-Simulation.

Eingabe → Ausgabe

4 Eingangskanäle:

- Kristallmaske (Typ)
- Viskositätsfeld η
- Randbedingungen (v_x, v_z)

Ausgabe (Lernziel):

$\hat{\psi} \in \mathbb{R}^{256 \times 256}$

Abgeleitet (Nachschritt):

$\hat{\mathbf{v}} = \mathrm{curl}(\hat{\psi})$

Warum Stromfunktion ψ?

Definition der Stromfunktion:

$$v_x = \frac{\partial \psi}{\partial z}, \qquad v_z = -\frac{\partial \psi}{\partial x}$$

Inkompressibilität automatisch erfüllt:

$$\nabla \cdot \mathbf{v} = \frac{\partial v_x}{\partial x} + \frac{\partial v_z}{\partial z} = \frac{\partial^2 \psi}{\partial x \partial z} - \frac{\partial^2 \psi}{\partial z \partial x} = 0$$

(Satz von Schwarz: gemischte partielle Ableitungen kommutieren)

Das Netz lernt *nur* $\hat{\psi}$ – Inkompressibilität ist **strukturell** garantiert.

Vorteile

- Kein Divergenz-Strafterm nötig
- div rms $\approx 10^{-26}$
- Lernproblem: 2 Felder $\rightarrow$ 1 Skalar
- Fehleranalyse einfacher

Konsequenz

ε_v ist *immer* größer als ε_ψ: Ableitung (Nachschritt) verstärkt hochfrequente Fehler.

Verlustfunktionen

FNO – Composite-Loss

$$\mathcal{L} = \underbrace{\|\hat{\psi} - \psi\|_2^2}_{\text{MSE}} + \alpha \underbrace{\|\nabla\hat{\psi} - \nabla\psi\|_2^2}_{\text{Gradient-Term}} + \beta \underbrace{\|\hat{\psi}|_{\partial\Omega}\|_2^2}_{\text{Rand-Term}}$$

- α: Warmup über 5 Epochen, Zielwert 0.1
- $\beta = 0.01$ (Dirichlet: $\psi = 0$ am Rand)
- Gradient-Term erzwingt korrekte Ableitungen
- Rand-Term stellt $\hat{\psi}|_{\partial\Omega} = 0$ sicher

U-Net – Loss

$$\mathcal{L} = \|\hat{\psi} - \psi\|_2^2$$

Nur MSE – kein Gradient- oder Rand-Term.

Das Netz lernt implizit die Randwerte aus den Trainingsdaten.

Optimizer

U-Net:	Adam
FNO:	Adam + Grad-Clip ($\|\nabla\| \leq 1$)

Evaluationsmetriken & Best-Checkpoint-Strategie

Evaluationsmetriken:

Metrik	Bedeutung
$\varepsilon_{\psi}^{\text{rel}}$	Mittl. rel. L2 in ψ
	Hauptmetrik
$\varepsilon_{\mathbf{v}}^{\text{rel}}$	Mittl. rel. L2 in $\lvert\mathbf{v}\rvert$
$\varepsilon_{\psi}^{\text{max}}$	Maximaler Fehler in ψ
div rms	RMS-Divergenz ($\rightarrow 0$)

Best-Checkpoint-Strategie

Auswertung **nicht** am letzten Epoch, sondern am Epoch mit dem besten Validierungs-Loss.

Warum wichtig?

- Modell kann nach dem besten Punkt wieder schlechter werden
- Ohne LR-Scheduler: Oszillationen um Minimum möglich
- Bei Multi-Kristall (Exp. 2/3): starkes Overfitting (s. später)

Datengenerierung & Experiment-Übersicht

Datensätze (LaMEM-FEM):

- 1 000 Samples pro Kristallanzahl n
- Drei unabhängige Seeds: Training / Validierung / Test
- Gitter: 256×256, Auflösung $\approx 8\,\mathrm{m/px}$

Exp	Training	Test	OOD
1	$n = 1$	$n = 1$	–
2	$n = 1 \ldots 10$	$n = 1 \ldots 10$	$n = 11 \ldots 25$
3	$n = 1 \ldots 25$	$n = 1 \ldots 25$	$n = 26 \ldots 84$

- **Exp. 1**: Hyperparameter-Suche (lr, batch) – ein Kristall
- **Exp. 2**: Multi-Kristall-Generalisierung, OOD bis $n = 25$
- **Exp. 3**: Stress-Test mit extremem OOD bis $n = 84$

Trainingssetup & Hyperparameter

Parameter	U-Net	FNO
Batch-Größe	8 / 16	8 / 16
Epochen (Exp. 1)	180	100
Epochen (Exp. 2/3)	180	50 **
Optimizer	Adam	Adam + Clip
Loss	MSE	Composite*

*Composite: MSE + Gradient-Term + Rand-Term
**FNO Exp. 2/3 werden auf 100 Ep. aktualisiert.

Lernraten (beide Modelle):

10^{-4}	$5 \cdot 10^{-4}$
10^{-3}	$5 \cdot 10^{-3}$

Checkpoint-Strategie:
Bestes Modell nach Val-Loss wird gespeichert (nicht zwingend das letzte Epoch).

Modellarchitekturen: U-Net vs. FNO

U-Net (CNN-basiert)

- Encoder–Decoder mit Skip-Connections
- Faltungen: lokaler $k \times k$-Ausschnitt
- Stärke: scharfe Kanten, Kristallkontur
- Schwäche: globale Strömungsstruktur
- Translationsinvarianz eingebaut
- 32 Basiskanäle, 4 Encoder-Ebenen

FNO (Fourier Neural Operator)

- Operiert direkt im Fourier-Raum
- FFT $\rightarrow$ Modengewichtung $\rightarrow$ IFFT + lokaler linearer Bypass
- Stärke: globale Spektral-Features, $\mathcal{O}(N \log N)$
- Gitterunabhängig (theoretisch)
- Natürlich für glatte Stokes-Felder
- Width $= 64$, Depth $= 4$, Modes $= 16$

Beide Modelle: Eingabe $256 \times 256 \times 4$, Ausgabe $256 \times 256 \times 1$ ($\hat{\psi}$).
Geschwindigkeitsfeld $\hat{\mathbf{v}} = \mathrm{curl}(\hat{\psi})$ als Nachschritt – kein eigenes Lernziel.

Exp 1 – FNO Hyperparameter-Suche (100 Epochen)

Batch-Größe 16:

Lernrate	$\varepsilon_\psi^{\text{rel}}$	$\varepsilon_v^{\text{rel}}$	
5×10^{-4}	**2.26 %**	4.56 %	← best
5×10^{-3}	2.39 %	4.03 %	
10^{-3}	2.75 %	4.05 %	
10^{-4}	4.31 %	–	

Batch-Größe 8 (vorläufig, 2/4):

Lernrate	$\varepsilon_\psi^{\text{rel}}$	$\varepsilon_v^{\text{rel}}$	
5×10^{-3}	**1.70 %**	3.07 %	← best
10^{-3}	3.20 %	3.91 %	
5×10^{-4}	*(ausstehend)*		
10^{-4}	*(ausstehend)*		

Beobachtungen:

- Optimales Fenster: lr $\in [5\times10^{-4}, 5\times10^{-3}]$
- Kleinere Batch-Größe hilft – bs = 8 verbessert bs = 16 von 2.26 % auf 1.70 %
- lr = 10^{-4}: kaum Konvergenz in 100 Epochen

Exp 1 – U-Net Hyperparameter-Suche (180 Epochen, Best-Checkpoint)

Batch-Größe 8:

Lernrate	$\varepsilon_\psi^{\text{rel}}$	$\varepsilon_v^{\text{rel}}$	
10^{-3}	**5.17 %**	16.3 %	← best
5×10^{-3}	5.31 %	15.1 %	
5×10^{-4}	5.44 %	16.3 %	
10^{-4}	6.51 %	20.3 %	

Batch-Größe 16:

Lernrate	$\varepsilon_\psi^{\text{rel}}$	$\varepsilon_v^{\text{rel}}$
10^{-3}	8.56 %	23.6 %
5×10^{-4}	9.85 %	21.3 %
10^{-4}	10.4 %	26.4 %
5×10^{-3}	11.2 %	24.4 %

Beobachtungen:

- **Batch 8 deutlich besser als Batch 16** – 5.17 % vs. 8.56 %
- Velocity-Fehler $\approx 3\times$ größer als ψ-Fehler (Ableitung als Nachschritt)
- Lernrate 10^{-3} optimal für bs = 8; Variation hat mäßigen Einfluss

Exp 1 – Trainingskurven (jeweils bestes Modell)

FNO (bs = 16, lr = 5×10^{-4}, 100 Ep.)

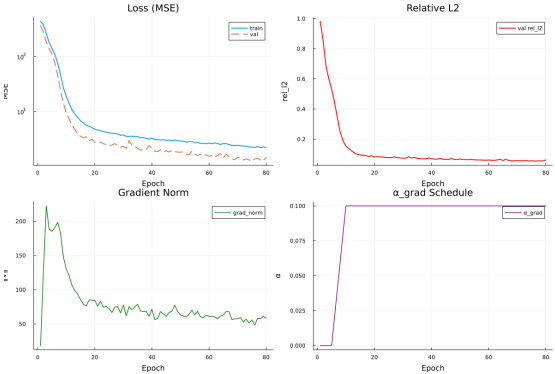

Schnelle Konvergenz (∼20 Ep.). Val-Loss ≤ Train-Loss. Gradient-Term stabilisiert zweite Phase.

U-Net (bs = 8, lr = 10^{-3}, 180 Ep.)

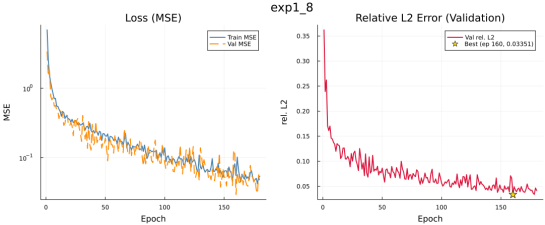

Konvergenz bis Ep. ≈160, Best-Checkpoint Ep. 160. Val/Train am Ende: ≈ 0.8× – kein Overfitting.

Exp 1 – Qualitative Ergebnisse: Stromfunktion ψ

FNO (bs = 16) $\varepsilon_\psi^{\text{rel}} = 1.32\,\%$

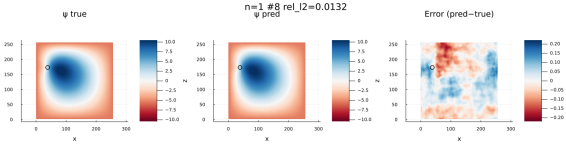

U-Net (bs = 8) $\varepsilon_\psi^{\text{rel}} = 3.41\,\%$

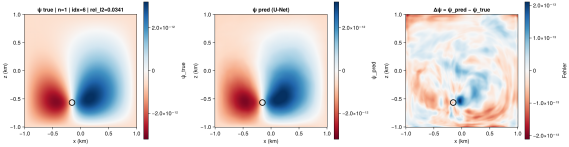

Bildlayout: Referenz (LaMEM) — Vorhersage (NN) — Absoluter Fehler $\Delta\psi$

FNO-Fehler diffus und klein; U-Net zeigt leicht stärkere Abweichungen am Kristallrand.

Exp 2 – Fehler vs. Kristallanzahl (Training $n = 1$–10)

U-Net (180 Ep., Best-Checkpoint Ep. 43)

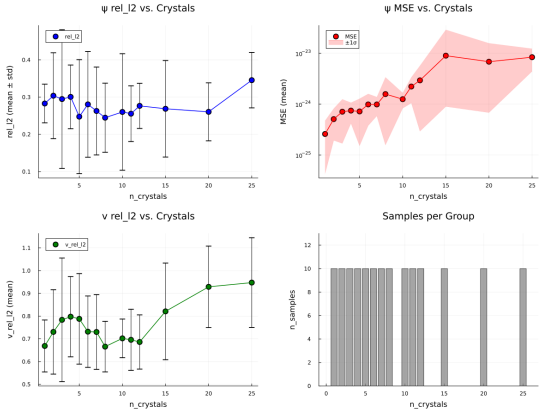

In-dist ($n \leq 10$): $\varepsilon_\psi \approx 24$–$30\,\%$

OOD $n = 25$: $\varepsilon_\psi = 34.5\,\%$, $\varepsilon_v = 94.7\,\%$

FNO (50 Ep. *)

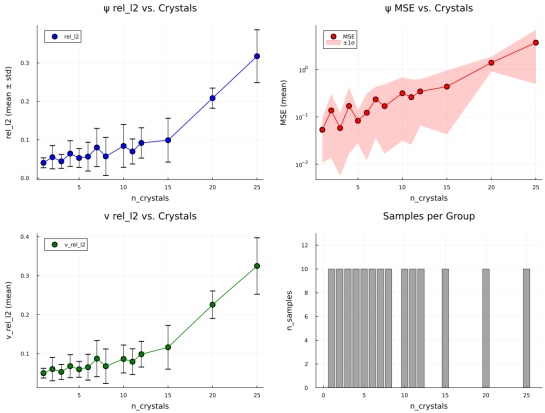

In-dist ($n \leq 10$): $\varepsilon_\psi \approx 4$–$7\,\%$

OOD $n = 25$: $\varepsilon_\psi = 31.8\,\%$, $\varepsilon_v = 32.5\,\%$

FNO in-distribution $\approx 5\times$ besser als U-Net. *FNO noch bei 50 Ep. – wird auf 100 Ep. aktualisiert.

Exp 2 – FNO: In-Distribution vs. Out-of-Distribution

In-Distribution $(n = 8,\ \varepsilon_\psi = 3.0\,\%)$

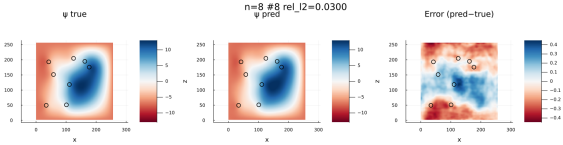

Out-of-Distribution $(n = 25,\ \varepsilon_\psi = 26.1\,\%)$

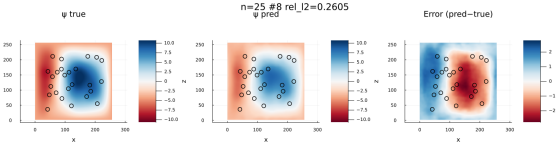

Bei $n = 8$ (Trainingsbereich): FNO generalisiert sehr gut. Bei $n = 25$ (2.5× mehr Kristalle als trainiert): sichtbare Abweichungen, globale Strömungsstruktur aber noch qualitativ korrekt.

Exp 3 – Fehler vs. Kristallanzahl (Training $n = 1$–25)

U-Net (180 Ep., Best-Checkpoint Ep. 30)

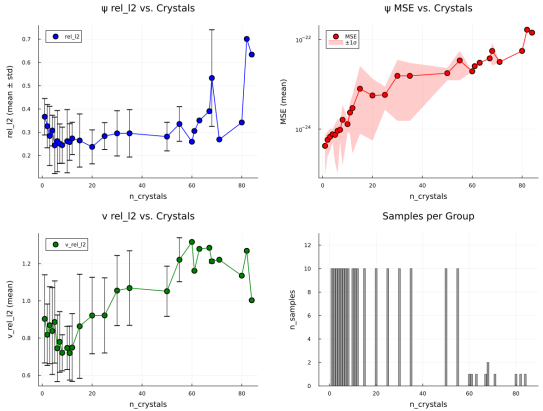

In-dist ($n \leq 25$): $\varepsilon_\psi \approx 24$–$37\,\%$
OOD $n = 82$: $\varepsilon_\psi \approx 70\,\%$

FNO (50 Ep. *)

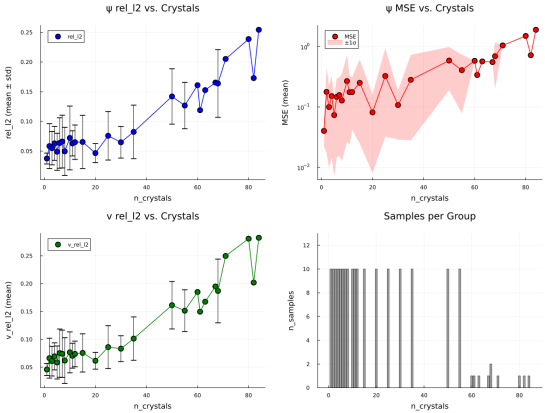

In-dist ($n \leq 25$): $\varepsilon_\psi \approx 4$–$10\,\%$
OOD $n = 60$: $16.1\,\%$; OOD $n = 84$: $25.4\,\%$

FNO bleibt auch im extremen OOD-Bereich unter $30\,\%$ – U-Net divergiert. *FNO noch bei 50 Ep.

Exp 3 – FNO: Extremes Out-of-Distribution ($n = 84$)

In-Distribution $(n = 25,\ \varepsilon_\psi = 5.3\,\%)$

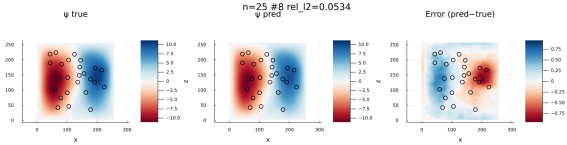

Extremes OOD $(n = 84,\ \varepsilon_\psi = 25.4\,\%)$

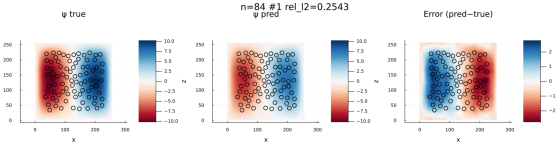

Bei $n = 84$ Kristallen ($3.4\times$ mehr als im Training) bleibt die globale Strömungsstruktur qualitativ erkennbar. Fehler steigt graduell – keine Divergenz.

Overfitting-Analyse: U-Net (alle Experimente)

Konfiguration	Best-Ep.	Train-MSE$_{\text{Ende}}$	Val-MSE$_{\text{Ende}}$	Val/Train
Exp-1 (bs $= 8$, lr $= 10^{-3}$)	160	0.054	0.045	0.8× ✓
Exp-2 ($n = 1$–10)	**43**	0.181	3.589	**20**×
Exp-3 ($n = 1$–25)	**30**	0.152	3.382	**22**×

- **Exp-1**: Val-Loss $\leq$ Train-Loss am Ende – kein Overfitting
- **Exp-2/3**: Best-Checkpoint sehr früh (Ep. 30–43 von 180); danach sinkt Train-Loss weiter, Val-Loss *steigt*
- Val/Train-Verhältnis von 20×–22× ist ein klares Overfitting-Signal
- Die **Best-Checkpoint-Strategie** rettet die Evaluation – finale Gewichte wären deutlich schlechter

Overfitting-Analyse: Ursachen & Gegenmaßnahmen

Warum tritt Overfitting auf?

- **Kein Regularisierung**: kein Dropout, kein Weight Decay
- **Kein LR-Scheduler**: konstante Lernrate bis Trainingsende
- **Komplexere Aufgabe**: Multi-Kristall ist schwieriger als Single-Kristall, gleiche Architektur
- **Weniger Daten pro Konfiguration**: bei $n = 1$–10 nur 1 000 Samples pro n

Mögliche Gegenmaßnahmen

1. **LR-Scheduling**
   z.B. Cosine Annealing oder ReduceLROnPlateau
2. **Regularisierung**
   L2 Weight Decay oder Dropout in Skip-Connections
3. **Mehr Trainingsdaten**
   insbesondere für $n > 10$
4. **Early Stopping** (explizit)
   derzeit: Best-Checkpoint als Näherung

Gesamtvergleich: FNO vs. U-Net

Experiment	Modell	$\varepsilon_\psi^{\text{rel}}$	$\varepsilon_v^{\text{rel}}$
Exp-1 ($n = 1$)	**FNO** (bs = 8, 100 Ep., vorläufig)	**1.70 %**	**3.07 %**
	U-Net (bs = 8, 180 Ep.)	5.17 %	16.3 %
Exp-2 (in-dist, $n \leq 10$)	**FNO** (bs = 16, 50 Ep.*)	**≈ 4–7 %**	≈ 5–7 %
	U-Net (bs = 16, 180 Ep.)	≈ 24–30 %	≈ 67–79 %
Exp-3 (in-dist, $n \leq 25$)	**FNO** (bs = 16, 50 Ep.*)	**≈ 4–10 %**	≈ 5–8 %
	U-Net (bs = 16, 180 Ep.)	≈ 24–37 %	≈ 74–92 %

*FNO Exp. 2/3 noch bei 50 Ep.; Aktualisierung auf 100 Ep. ausstehend.
FNO bs = 8 für Exp. 1 noch unvollständig (2/4 Konfigurationen).

Fazit & Nächste Schritte

Was erreicht wurde

- Vollständige Train-/Val-/Eval-Pipeline
- Systematische Hyperparameter-Suche abgeschlossen
- **FNO**: $\varepsilon_\psi < 2.3\,\%$ bei $n = 1$ (bs $= 16$), vorläufig $1.7\,\%$ mit bs $= 8$
- **FNO**: $\approx$ 4–10 % für Multi-Kristall (in-dist)
- **U-Net**: $5.2\,\%$ bei $n = 1$, aber Overfitting bei Multi-Kristall
- Inkompressibilität garantiert (div rms ≈ 0)

Offene Punkte

1. Max-Fehler FNO: 30–90 % am Kristallrand
2. U-Net: Overfitting Exp. 2/3
3. FNO Exp. 2/3 noch 50 Ep.
4. FNO bs $= 8$ unvollständig

Nächste Schritte

1. FNO Exp. 2/3 $\rightarrow$ 100 Epochen
2. LR-Scheduler + L2-Reg. (U-Net)
3. Fehleranalyse Kristallrand
4. Experiment 4: Kristallgröße