Neuronale Operatoren zur Strömungssimulation um Kristalle

U-Net vs. Fourier Neural Operator – Aktueller Stand

Paul Baselt

Betreuer-Meeting – Masterarbeit

26. März 2026

Agenda

Physikalische Situation & Lernziel

Setup:

- Kristalle eingebettet in viskose Matrix
- Gebiet: 256×256-Gitter, $[-1, 1]^2$ km
- Stokes-Gleichungen (niedrige Reynolds-Zahl):

$$-\nabla p + \eta \, \Delta \mathbf{v} = 0, \qquad \nabla \cdot \mathbf{v} = 0$$

- Numerische Referenz: **LaMEM** (FEM-Solver) – korrekt, aber rechenintensiv

Ziel: Neuronales Netz sagt Strömungsfeld vorher – *ohne* FEM-Simulation.

Eingabe → Ausgabe

4 Eingangskanäle:

- Kristallmaske (Typ)
- Normalisierte x- und z Koordinaten
- Signed Distance Field (SDF)

Ausgabe (Lernziel):

$\hat{\psi} \in \mathbb{R}^{256 \times 256}$

Abgeleitet (Nachschritt):

$\hat{\mathbf{v}} = \mathrm{curl}(\hat{\psi})$

Warum Stromfunktion ψ?

Definition der Stromfunktion:

$$v_x = \frac{\partial \psi}{\partial z}, \qquad v_z = -\frac{\partial \psi}{\partial x}$$

Inkompressibilität automatisch erfüllt:

$$\nabla \cdot \mathbf{v} = \frac{\partial v_x}{\partial x} + \frac{\partial v_z}{\partial z} = \frac{\partial^2 \psi}{\partial x \partial z} - \frac{\partial^2 \psi}{\partial z \partial x} = 0$$

(Satz von Schwarz: gemischte partielle Ableitungen kommutieren)

Das Netz lernt *nur* $\hat{\psi}$ – Inkompressibilität ist **strukturell** garantiert.

Vorteile

- Kein Divergenz-Strafterm nötig
- Lernproblem: 2 Felder $\rightarrow$ 1 Skalar
- Fehleranalyse einfacher

Konsequenz

ε_v ist *immer* größer als ε_ψ: Ableitung (Nachschritt) verstärkt hochfrequente Fehler.

Verlustfunktionen

FNO – Composite-Loss

$$\mathcal{L} = \underbrace{\|\hat{\psi} - \psi\|_2^2}_{\text{MSE}} + \alpha \underbrace{\|\nabla\hat{\psi} - \nabla\psi\|_2^2}_{\text{Gradient-Term}} + \beta \underbrace{\|\hat{\psi}|_{\partial\Omega}\|_2^2}_{\text{Rand-Term}}$$

- α: Warmup über 5 Epochen, Zielwert 0.1
- $\beta = 0.01$ (Dirichlet: $\psi = 0$ am Rand)
- Gradient-Term erzwingt korrekte Ableitungen
- Rand-Term stellt $\hat{\psi}|_{\partial\Omega} = 0$ sicher

U-Net – Loss

$$\mathcal{L} = \|\hat{\psi} - \psi\|_2^2$$

Nur MSE – kein Gradient- oder Rand-Term.

Das Netz lernt implizit die Randwerte aus den Trainingsdaten.

Optimizer

Adam für beide

Evaluationsmetriken & Best-Checkpoint-Strategie

Evaluationsmetriken:

Metrik	Bedeutung
$\varepsilon_{\psi}^{\text{rel}}$	Mittl. rel. L2 in ψ
	Hauptmetrik
$\varepsilon_{\mathbf{v}}^{\text{rel}}$	Mittl. rel. L2 in $\lvert\mathbf{v}\rvert$
$\varepsilon_{\psi}^{\text{max}}$	Maximaler Fehler in ψ
div rms	RMS-Divergenz ($\rightarrow 0$)

Best-Checkpoint-Strategie

Auswertung **nicht** am letzten Epoch, sondern am Epoch mit dem besten Validierungs-Loss.

Warum wichtig?

- Modell kann nach dem besten Punkt wieder schlechter werden
- Ohne LR-Scheduler: Oszillationen um Minimum möglich

Datengenerierung & Experiment-Übersicht

Datensätze (LaMEM-FEM):

- Drei unabhängige Seeds: Training / Validierung / Test
- Training 1000 Samples pro Kristallzahl n
- Validierung 100 Samples pro Kristallzahl n
- Training 10 Samples pro Kristallzahl n

Exp	Training	Test	OOD
1	$n = 1$	$n = 1$	–
2	$n = 1 \ldots 10$	$n = 1 \ldots 10$	$n = 11 \ldots 25$
3	$n = 1 \ldots 25$	$n = 1 \ldots 25$	$n = 26 \ldots 84$

- **Exp. 1**: Hyperparameter-Suche (lr, batch) – ein Kristall
- **Exp. 2**: Multi-Kristall-Generalisierung, OOD bis $n = 25$
- **Exp. 3**: Stress-Test mit extremem OOD bis $n = 84$

Trainingssetup & Hyperparameter

Parameter	U-Net	FNO
Batch-Größe	8 / 16	8 / 16
Epochen (Exp. 1)	180	100
Optimizer	Adam	Adam + Clip
Loss	Composite*	Composite*

*Composite: MSE + Gradient-Term + Rand-Term

Lernraten (beide Modelle):

10^{-4}	$5 \cdot 10^{-4}$
10^{-3}	$5 \cdot 10^{-3}$

Checkpoint-Strategie:
Bestes Modell nach Val-Loss wird gespeichert (nicht zwingend das letzte Epoch).

Modellarchitekturen: U-Net vs. FNO

U-Net (CNN-basiert)

- Encoder–Decoder mit Skip-Connections
- Faltungen: lokaler $k \times k$-Ausschnitt
- Stärke: scharfe Kanten, Kristallkontur
- Schwäche: globale Strömungsstruktur
- 32 Basiskanäle, 4 Encoder-Ebenen

FNO (Fourier Neural Operator)

- Operiert direkt im Fourier-Raum
- FFT $\rightarrow$ Modengewichtung $\rightarrow$ IFFT + lokaler linearer Bypass
- Stärke: globale Spektral-Features, $\mathcal{O}(N \log N)$
- Gitterunabhängig (theoretisch)
- Natürlich für glatte Stokes-Felder
- Width $= 64$, Depth $= 4$, Modes $= 16$

Beide Modelle: Eingabe $256 \times 256 \times 4$, Ausgabe $256 \times 256 \times 1$ ($\hat{\psi}$).
Geschwindigkeitsfeld $\hat{\mathbf{v}} = \mathrm{curl}(\hat{\psi})$ als Nachschritt – kein eigenes Lernziel.

Exp 1 – FNO Hyperparameter-Suche (100 Epochen)

Batch-Größe 8:

Lernrate	$\varepsilon_\psi^{\text{rel}}$	$\varepsilon_v^{\text{rel}}$	
5×10^{-4}	2.61 %	3.82 %	
5×10^{-3}	**2.07 %**	4.13 %	← best
10^{-3}	4.18 %	4.89 %	
10^{-4}	5.85 %	10.56 %	

Batch-Größe 16:

Lernrate	$\varepsilon_\psi^{\text{rel}}$	$\varepsilon_v^{\text{rel}}$	
5×10^{-4}	**1.62 %**	3.44 %	← best
10^{-4}	5.10 %	8.18 %	
10^{-3}	2.06 %	3.02 %	
5×10^{-3}	2.31 %	4.15 %	

Beobachtungen:

- Optimales Fenster: lr $\in [5\times10^{-4}, 5\times10^{-3}]$
- Kleinere Batch-Größe hilft – bs = 8 verbessert bs = 16 von 2.07 % auf 1.62 %

Exp 1 – U-Net Hyperparameter-Suche (180 Epochen, Best-Checkpoint)

Batch-Größe 8:

Lernrate	$\varepsilon_\psi^{\text{rel}}$	$\varepsilon_v^{\text{rel}}$
10^{-3}	6.0 %	9.3 %
5×10^{-3}	5.5 %	8.5 %
5×10^{-4}	5.9 %	9.6 %
10^{-4}	6.5 %	12.7 %

Batch-Größe 16:

Lernrate	$\varepsilon_\psi^{\text{rel}}$	$\varepsilon_v^{\text{rel}}$
10^{-3}	13.9 %	22.1 %
5×10^{-4}	15 %	29.9 %
10^{-4}	13.5 %	23.1 %
5×10^{-3}	24.0%	24.4 %

Beobachtungen:

- **Batch 8 deutlich besser als Batch 16** – 5.17 % vs. 8.56 %
- Velocity-Fehler $\approx 3\times$ größer als ψ-Fehler (Ableitung als Nachschritt)
- Lernrate 10^{-3} optimal für bs = 8; Variation hat mäßigen Einfluss

Exp 1 – Trainingskurven (jeweils bestes Modell)

FNO (bs = 16, lr = 5×10^{-4}, 100 Ep.)

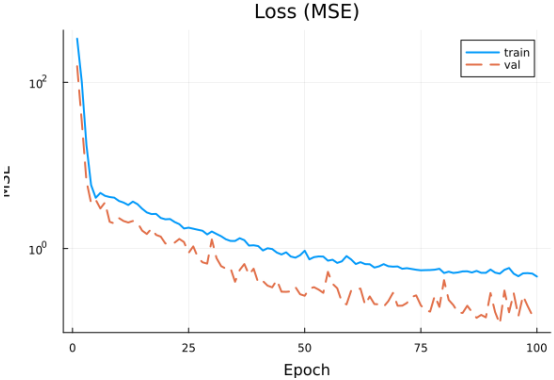

FNO (bs = 8, lr = 5×10^{-3}, 180 Ep.)

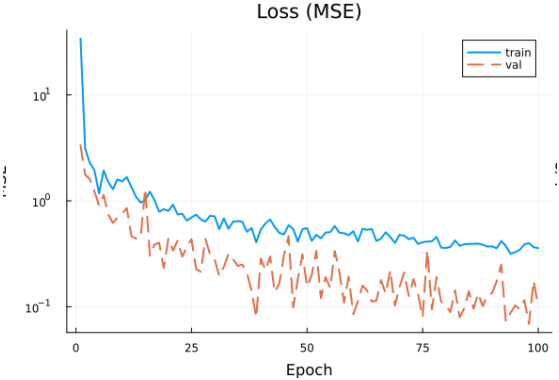

Exp 1 – Qualitative Ergebnisse: Stromfunktion ψ

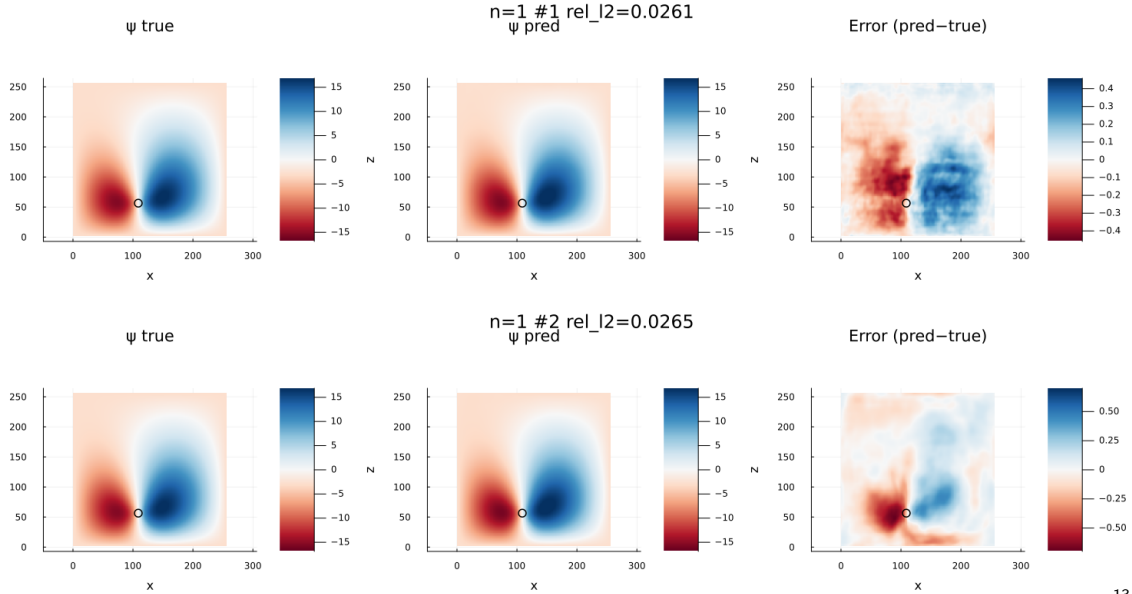

Exp 1 – Qualitative Ergebnisse: Stromfunktion ψ

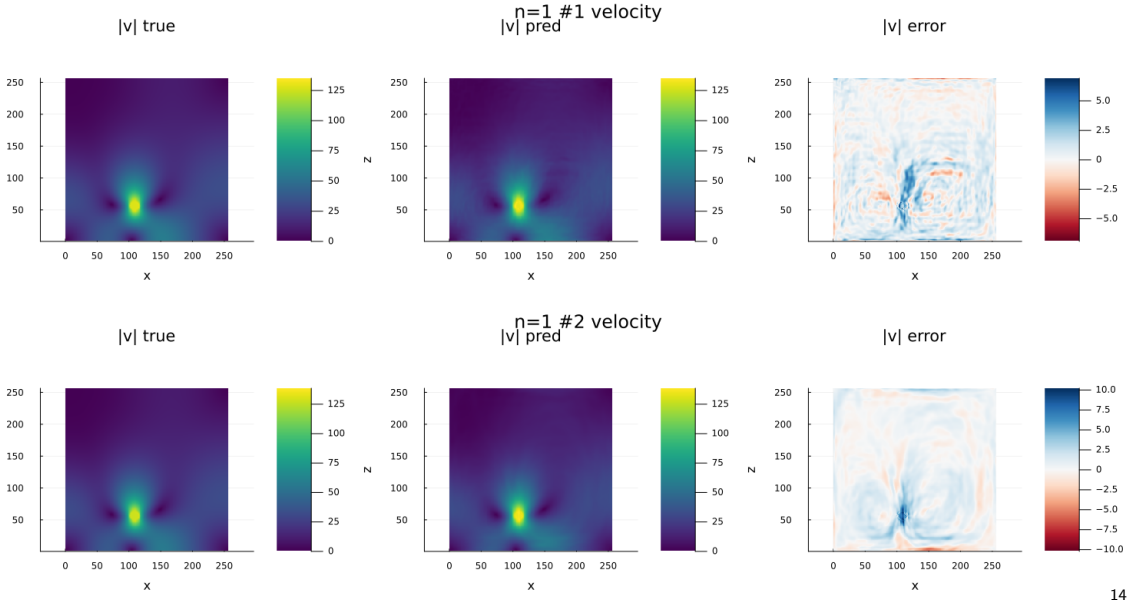

Exp 1 – Trainingskurven (jeweils bestes Modell)

U-Net (bs = 8, lr = 5×10^{-3}, 180 Ep.)

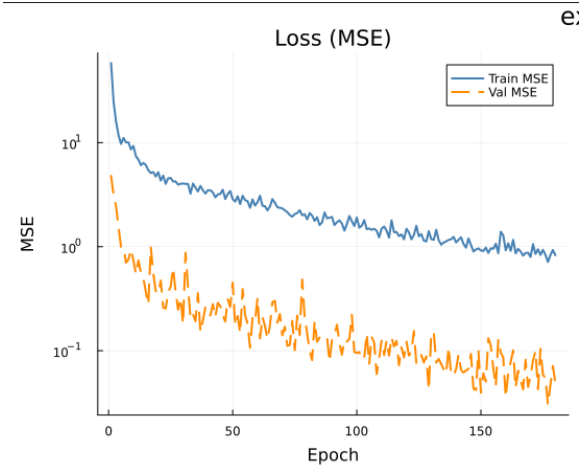

Exp 1 – Qualitative Ergebnisse: Stromfunktion ψ

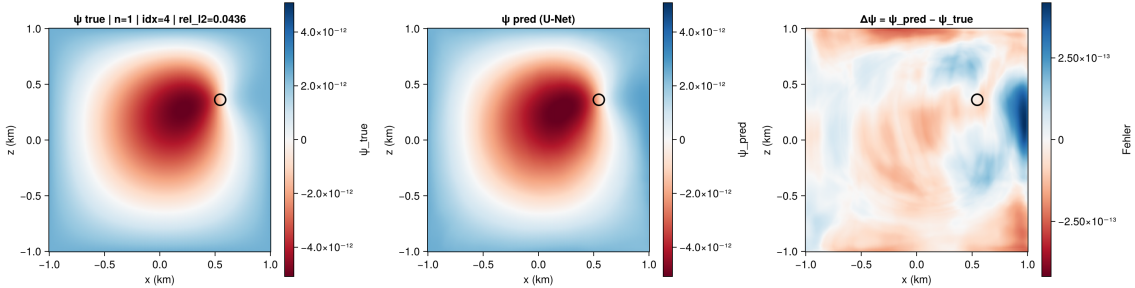

Referenz (LaMEM) — Vorhersage — Absoluter Fehler $\Delta\psi$

U-Net-Fehler diffus und klein; U-Net zeigt leicht stärkere Abweichungen am Kristallrand.

Exp 1 – Qualitative Ergebnisse: Stromfunktion ψ

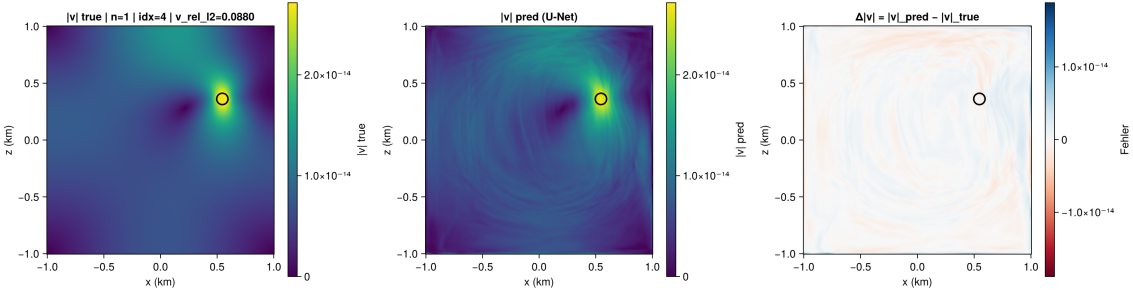

Referenz (LaMEM) — Vorhersage — Absoluter Fehler Δv

U-Net-Fehler diffus und klein; U-Net zeigt leicht stärkere Abweichungen am Kristallrand.

Gesamtvergleich: FNO vs. U-Net

Experiment	Modell	$\varepsilon_{\psi}^{\text{rel}}$	$\varepsilon_{v}^{\text{rel}}$
Exp-1 ($n = 1$)	**FNO** (bs = 16, 100 Ep.)	**1.62 %**	**3,44 %**
	U-Net (bs = 8, 180 Ep.)	5.5 %	8.5 %