Surrogate Modeling of Stokes Flow Around Settling Crystals

FNO vs. U-Net: Results Overview

Paul Baselt

Betreuergespräch, March 19, 2026

Motivation & Ziel

Problem: Numerische Stokes-Strömungssimulationen für kristallreiche Magmen sind rechenintensiv.

Ziel: Zwei datengetriebene Surrogatmodelle vergleichen, die das Stromfunktionsfeld ψ direkt aus der Kristallkonfiguration vorhersagen:

- **FNO** – Fourier Neural Operator (spektral, global)
- **U-Net** – Convolutional Encoder–Decoder (lokal)

Eingabe: 5 Kanäle auf 256×256 Gitter (Maske, SDF, Radius, x-Koord., z-Koord.)

Ausgabe: $\hat{\psi} \in \mathbb{R}^{256 \times 256}$

Verlustfunktion:

$$\mathcal{L} = \underbrace{\mathrm{MSE}(\hat{\psi}, \psi)}_{\text{Punktgenauigkeit}} + \alpha_{\text{grad}} \underbrace{\mathcal{L}_{\text{grad}}}_{\text{Gradienten}} + \alpha_{\text{bnd}} \underbrace{\mathcal{L}_{\text{b}}}_{\text{Rand}}$$

α_{grad}: lineares Ramp-up 0→0.1 in Epoche 1–5

$\alpha_{\text{bnd}} = 0.01$ (fest)

Hardware: NVIDIA A100 GPU

Warum Stromfunktion? — Analytische Divergenzfreiheit

Inkompressibilitätsbedingung (Stokes-Strömung):

$$\nabla \cdot \mathrm{u} = \frac{\partial u_x}{\partial x} + \frac{\partial u_z}{\partial z} = 0$$

Stromfunktion ψ — Definition der Geschwindigkeit:

$$u_x = \frac{\partial \psi}{\partial z}, \qquad u_z = -\frac{\partial \psi}{\partial x}$$

Nachweis der Divergenzfreiheit:

$$\nabla \cdot \mathrm{u} = \frac{\partial^2 \psi}{\partial x \partial z} - \frac{\partial^2 \psi}{\partial z \partial x} = 0 \quad \checkmark$$

Gilt für *jede* glatte Funktion ψ

Konsequenzen für das Surrogatmodell:

- Divergenz-RMS aller FNO-Vorhersagen: $\sim 10^{-26}$
- Physikalische Konsistenz analytisch garantiert — kein expliziter Divergenz-Strafterm nötig
- Geschwindigkeit aus ψ per Finite-Differenzen: Fehler in ψ werden durch Ableitung *verstärkt* $\Rightarrow$ Gradient-Loss reduziert Hochfrequenzartefakte

Experimentübersicht

Exp.	Training	OOD-Evaluation	Epochen
1 – Einzelkristall-Baseline	$n = 1,\ r = 0.05$	–	FNO: 100, U-Net
2 – Mehrkristall-General.	$n \in \{1, \ldots, 10\}$	$n = 11 \ldots 25$	FNO: 100, U-Net
3 – Stress-Test	$n \in \{1, \ldots, 25\}$	$n = 30 \ldots 84$	FNO: 100, U-Net
4a – Größen-Baseline	Modell aus Exp. 1 ($r = 0.05$)	$r = 0.005,\ r = 0.5$	kein Training
4b – Variable-Radius (FNO)	$r \in \{0.02, 0.05, 0.08\}$	$r = 0.035, 0.075$ (Interp.) $r = 0.01, 0.1$ (Extrap.)	100

Je 1 000 Training / 100 Validierung / 10 Evaluation Samples pro Stratum (Exp. 1–3).
Hyperparameter-Suche in Exp. 1: 4 Lernraten $\times$ 2 Batch-Größen $= 8$ Konfigs pro Modell.

Experiment 1: Einzelkristall-Baseline

Beste Konfigurationen (10 Eval-Samples):

Modell	**Konfig**	$\bar{\varepsilon}_\psi$	$\bar{\varepsilon}_v$
FNO	5×10^{-4}, bs 16	**1.62%**	**3.44%**
FNO	5×10^{-3}, bs 8	2.07%	4.13%
U-Net	5×10^{-3}, bs 8	5.5%	8.5%
U-Net	1×10^{-4}, bs 16	13.5%	23.1%

- FNO: 3.4× besser als U-Net auf ψ
- Gradient-Loss: Verhältnis $\varepsilon_v/\varepsilon_\psi$ von $\sim 3\times$ auf ~ 1.5–$2\times$ reduziert
- FNO: bs 16 $>$ bs 8; U-Net: bs 8 $\gg$ bs 16

Experiment 1: Einzelkristall-Baseline

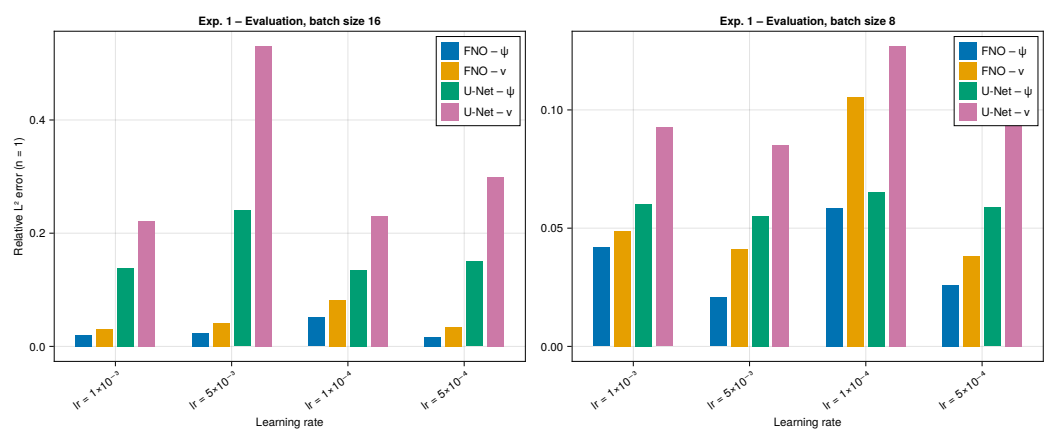

Evaluierungsfehler aller lr-Konfigurationen (bs 16 links, bs 8 rechts).

Experiment 1: Qualitative Vorhersage (FNO, bs 16)

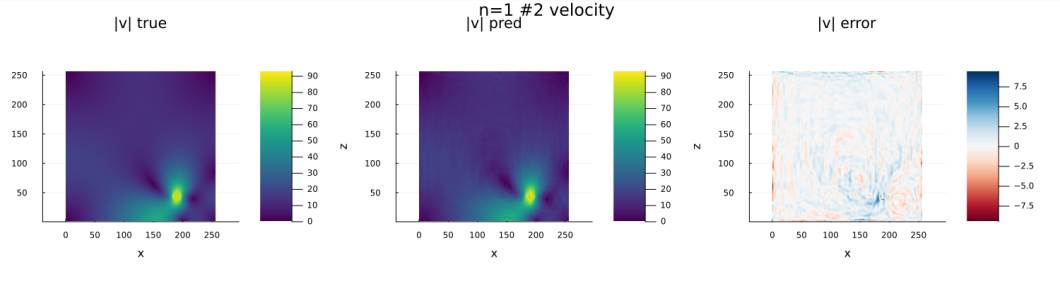

FNO Exp-1.4 (5×10^{-4}, bs 16): Stromfunktion ψ und Geschwindigkeitsbetrag $|u|$ — Vorhersage vs. numerische Referenz, unnormalisiert.

Experiment 2 & 3: Mehrkristall-Generalisierung

Exp. 2 (Training $n \leq 10$, FNO: 100 Ep., U-Net: 180 Ep.):

Modell	$\varepsilon_\psi^{\text{in-dist}}$	$\varepsilon_\psi^{n=25}$
FNO	$\sim 5.5\%$	13.8%
U-Net	$\sim 22\%$	26.8%

Exp. 3 (Training $n \leq 25$, FNO: 100 Ep., U-Net: 180 Ep.):

Modell	$\varepsilon_\psi^{\text{in-dist}}$	$\varepsilon_\psi^{n=50}$
FNO	$\sim 6.8\%$	12.4%
U-Net	$\sim 23\%$	21.5%

- FNO: 3–4× besser in-dist.
- U-Net saturiert früh (Ep. 43/49, $\sim 28\%$) $\Rightarrow$ kein Vorteil durch längeres Training
- Größeres Trainingsset ($n \leq 25$) verlängert FNO-Generalisierungsbereich deutlich: bis $n = 30$ kaum Degradation
- OOD-Vorteil FNO: 2× bei $n = 25$, 1.7× bei $n = 50$

Exp. 2 & 3: FNO-Generalisierung über Kristallzahl

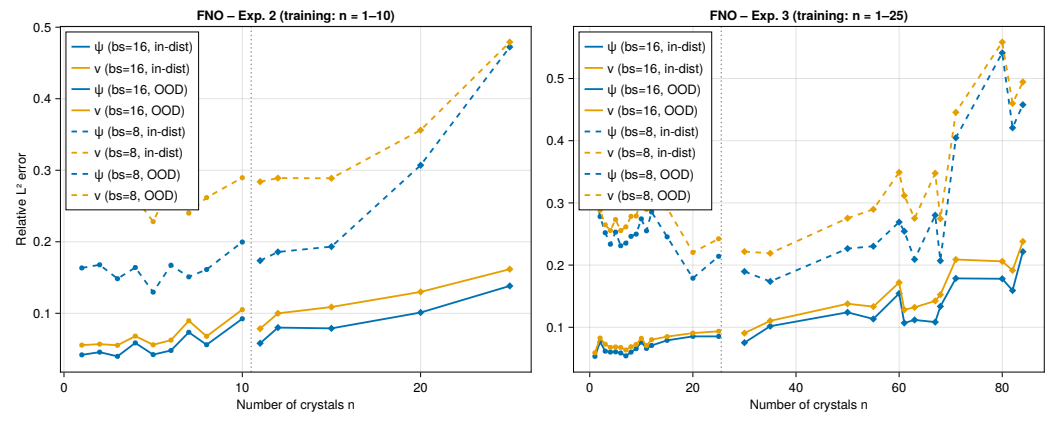

FNO: relativer L_2-Fehler auf ψ vs. Kristallzahl für Exp. 2 (links, Training $n \leq 10$) und Exp. 3 (rechts, Training $n \leq 25$). Gestrichelt = OOD. Vertikale Linie: Trainingsgrenze.

Exp. 2 & 3: U-Net-Generalisierung über Kristallzahl

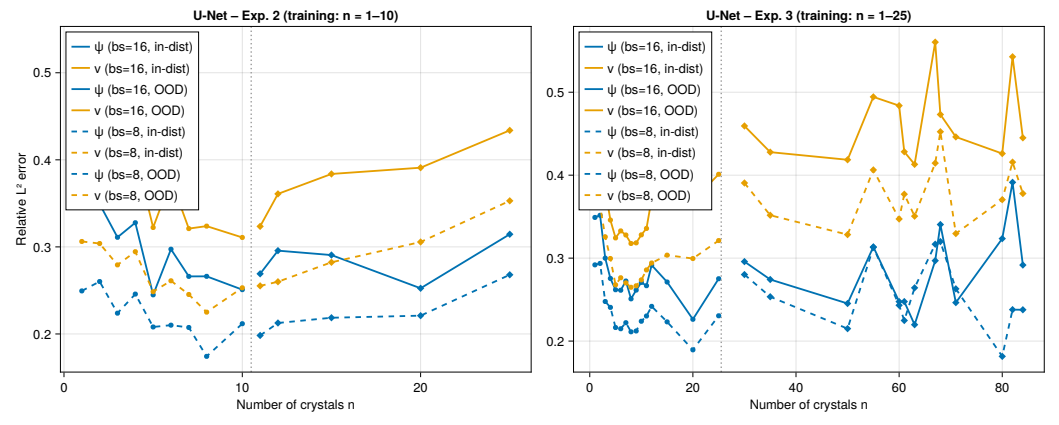

U-Net: relativer L_2-Fehler auf ψ vs. Kristallzahl für Exp. 2 (links) und Exp. 3 (rechts). Fehler bleiben durchgehend hoch; Differenz zwischen in-dist. und OOD ist gering.

Experiment 4a: Kristallgröße — Fixed-Radius Baseline

Setup: Bestes Modell aus Exp. 1 (trainiert auf $r = 0.05$) wird ohne Neutraining auf OOD-Größen evaluiert.

Modell	**Radius**	$\bar{\varepsilon}_\psi$	$\bar{\varepsilon}_v$
FNO	klein ($r = 0.005$)	12.1%	20.4%
FNO	groß ($r = 0.5$)	71.3%	67.7%
U-Net	klein ($r = 0.005$)	10.8%	20.1%
U-Net	groß ($r = 0.5$)	44.9%	50.7%

- **Kleine Kristalle:** globales Strömungsfeld dominiert — beide Architekturen robust
- **Große Kristalle:** FNO versagt — hohe Ortsfrequenzen nahe der Grenzfläche übersteigen $k_{\max} = 16$
- U-Net hier besser — lokale Faltungen besser geeignet für scharfe räumliche Gradienten

Exp. 4a: Größen-Generalisierung (Fixed-Radius)

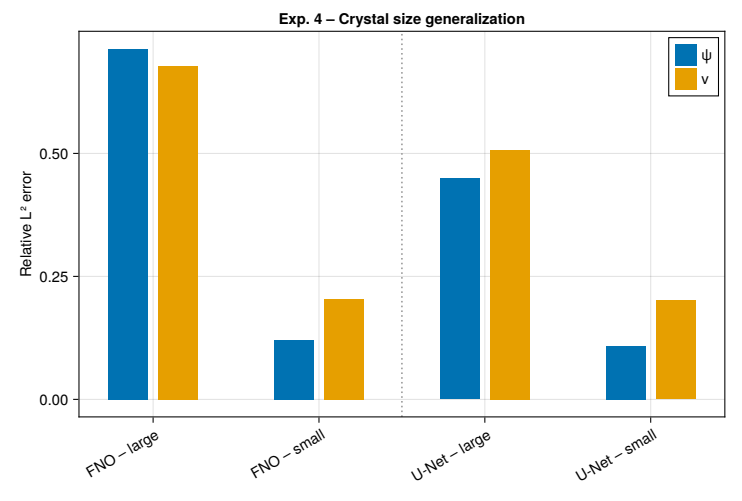

Relativer L_2-Fehler auf ψ und $|u|$ für FNO und U-Net auf kleinen ($r = 0.005$) und großen ($r = 0.5$) Kristallen. Training: $r = 0.05$.

Experiment 4b: Kristallgröße — Variable-Radius FNO

Setup: Neues FNO trainiert auf
$r \in \{0.02, 0.05, 0.08\}$
(je 1 000 Samples, 100 Epochen, bs 16,
$\mathrm{lr} = 5 \times 10^{-4}$)

Evaluation auf 70 Samples:

- In-Distribution: $r = 0.02$, $r = 0.08$
- Interpolation: $r = 0.035$, $r = 0.075$
- Extrapolation: $r = 0.01$, $r = 0.1$

Modell	$\bar{\varepsilon}_\psi$	$\bar{\varepsilon}_v$
FNO var.-Radius (gesamt)	10.35%	11.63%
Vergleich: FNO fix, groß OOD	71.3%	67.7%

Schlüsselergebnis:

- Radius-Eingangskanal ermöglicht Konditionierung auf Geometrie
- Hohe Streuung ($\pm$10.8%) — Extrapolationsradien ($r = 0.01$, $r = 0.1$) treiben den Fehler
- In-Distribution & Interpolation: deutlich besser als Extrapolation

Zusammenfassung & Fazit

FNO übertrifft U-Net in fast allen Szenarien:

	FNO	U-Net
Exp 1 (in-dist.)	1.62%	5.5%
Exp 2 (in-dist.)	$\sim$ 5.5%	$\sim$ 22%
Exp 2 OOD $n = 25$	13.8%	26.8%
Exp 3 (in-dist.)	$\sim$ 6.8%	$\sim$ 23%
Exp 3 OOD $n = 50$	12.4%	21.5%
Exp 4a groß OOD	71.3%	44.9%

Ausnahme: Große Kristalle — U-Net robuster durch lokale Faltungsarchitektur.

Schlüsselerkenntnisse:

- Stromfunktions-Ausgabe $\Rightarrow$ Divergenzfreiheit analytisch garantiert
- Gradient-Loss reduziert $\varepsilon_v/\varepsilon_\psi$-Verhältnis von 3$\times$ auf 1.5–2$\times$
- FNO konvergiert stabil; U-Net saturiert früh ($\sim$Ep. 43–49) bei Mehrkristall-Aufgaben
- Breiteres Trainingsset verlängert OOD-Generalisierungsbereich deutlich
- Variable-Radius-Training löst Größen-OOD-Problem